پروژه شماره ۳

درس مبانی بازیابی اطلاعات و جستجوی وب

هدف این پروژه، پیاده سازی الگوریتم SPIMI است

۱.مجموعه داده

مجموعه داده مورد نظر شامل تعدادی فایل متنی در فولدر data قرار دارد.

۲. صورت پروژه:

ابتدا اسناد را خوانده، متن مورد نظر را توکنایز کرده، سپس stop word (لیست توقف) ها را حذف کرده و term ها دیگشنری را در دو حالت زیر در نظر بگیرید:

۱- توکن ها به جز stop word ها
۲- توکن ها (به جز stop word ها) را ریشه یابی کرده و سپس ریشه ها را به عنوان term در نظر بگیرید.

شاخص وارون را بر اساس مجموعه متونی که دارید ایجاد کنید، با الگوریتم SPIMI پیاده سازی کنید. فرض کنید هر ۵ سند معادل یک بلوک داده هستند. تعداد اسناد هر بلوک در زمان تحویل پروژه باید قابل تغییر باشد. بعد از ساخت شاخص یک query یک کلمه ای از کاربر بگیرید و شماره یا عنوان اسناد نتیجه را در خروجی نشان دهید.

۳. نکات قابل توجه

- جهت پیاده سازی پروژه در زبان پایتون می توانید از کتابخانه nltk استفاده کنید. فایل لیست توقف زبان انگلیسی در این کتابخانه موجود است.
- در زمان ارائه، کد شما با مجموعه داده هایی علاوه برمجموعه داده فراهم شده در پروژه نیز تست خواهد شد.
- تمام فایل های پروژه شامل کد و فایل های خروجی از جمله فایل شاخص نهایی و شاخص های مرحله‌ی میانی را در فولدری با فرمت zip به نام Project3_studentNumber(s).zip ذخیره نموده و ارسال نمایید.
- دقت شود هدف این پروژه پیاده‌سازی الگوریتم SPIMI (و نه ساخت شاخص به هر روشی) است. لذا به ساخت شاخص با روش‌های دیگر نمره ای تعلق نمی گیرد.